

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



BÁO CÁO ĐỒ ÁN GIỮA KỲ
XÂY DỰNG NGỮ LIỆU SONG NGỮ HÁN - VIỆT
CHUYÊN NGÀNH LỊCH SỬ VIỆT NAM
(THỜI KỲ PHONG KIẾN)

Môn học: Xử Lý Ngôn Ngữ Tự Nhiên Nâng Cao

GVHD: PGS. TS. Đinh Điền

Học viên: 25C11027 – Bùi Quốc Việt
25C11006 – Nguyễn Tất Hưng
25C11011 – Nguyễn Ngọc Hồng Linh
25C11065 – Trần Quốc Thịnh

TP. HỒ CHÍ MINH, 07/2025

1 Giới thiệu đồ án

Đề tài 18: HVB: Xây dựng ngữ liệu song song Hán – Việt chuyên ngành lịch sử Việt Nam (phong kiến)

Mã số tác phẩm: HVB_001 đến HVB_005

Bài Toán: HVB - Xây dựng ngữ liệu song song Hán – Việt chuyên ngành lịch sử Việt Nam. Ngữ liệu cần được tách câu và đóng hàng chính xác ở cấp độ câu/cụm ý giữa văn bản Hán và bản Việt.

1.1 Mục tiêu của đồ án

Đồ án hướng đến việc xây dựng bộ ngữ liệu chuyên ngành lịch sử Việt Nam từ các tác phẩm cổ văn (chữ Hán, chữ Nôm và Quốc ngữ). Mục tiêu cốt lõi là tạo ra một pipeline tự động (end-to-end) có khả năng:

1. Trích xuất văn bản (OCR) từ các tài liệu cổ dưới dạng PDF Scan, ảnh chụp và PDF Text.
2. Tách câu, sửa từ và chuẩn hóa văn bản cổ (vốn không tuân theo quy tắc dấu câu hiện đại).
3. Đóng hàng (Sentence Alignment) để tạo ra ngữ liệu song song Hán – Việt, phục vụ cho các tác vụ NLP downstream như dịch máy, đối chiếu văn bản và nghiên cứu lịch sử.

1.2 Phạm vi dữ liệu và kết quả mong đợi

Phạm vi dữ liệu: Tập dữ liệu bao gồm 5 tác phẩm lịch sử phong kiến Việt Nam (HVB_001 đến HVB_005) với tổng cộng 1.848 trang văn bản. Chi tiết về tác giả, thể loại và độ khó của từng tác phẩm được thống kê cụ thể tại Bảng 2 ở Mục 2.

Yêu cầu kết quả đầu ra: Ngữ liệu được trích xuất và đóng hàng chính xác ở cấp độ câu/cụm ý để tạo thành corpus song song Hán-Việt. Kết quả xuất ra hai định dạng tệp tin quy định trong Bảng 1:

Loại output	Tên file	Định dạng	Nội dung
OCR thô	[matacpham]_raw.txt	Text	Toàn bộ văn bản trích xuất từ PDF/ảnh
Song ngữ	[matacpham]_parallel.tsv	TSV	Các cặp câu Hán-Việt đã đóng hàng

Bảng 1: Cấu trúc các định dạng dữ liệu đầu ra của pipeline

Thách thức đặc thù của bài toán:

- **Đa dạng định dạng & kiểu chữ:** Xử lý đồng thời từ PDF text layer, PDF scan khắc gỗ đến sách Nôm viết tay.
- **Bố cục đọc đúng:** Cổ thư Hán/Nôm đọc theo cột dọc (từ phải sang trái, từ trên xuống dưới), ngược với văn bản hiện đại.
- **Không có dấu câu chuẩn & chất lượng giấy kém:** Văn ngôn không có dấu ngắt câu thống nhất; chất liệu giấy dó bị ố vàng, lem mực gây nhiễu OCR.

2 Đặc tả dữ liệu và công cụ sử dụng

Tập dữ liệu HVB gồm 5 tác phẩm lịch sử với các đặc điểm kỹ thuật và độ khó xử lý được tóm tắt trong Bảng 2:

Bảng 2: Tóm tắt đặc tả kỹ thuật và mức độ khó của các tác phẩm trong tập dữ liệu HVB

Mã ID	Tên tác phẩm	Tác giả & Nội dung	Đặc điểm kỹ thuật	Độ khó
HVB_001	An Nam Chí Lược (安南志略)	Lê Tắc (20 quyển sử ký thời Trần)	PDF Text + HTML (c _{text} .org), font Hán hiện đại	Thấp
HVB_002	An Nam Chí Nguyên (安南志原)	Cao Hùng Trưng (Lịch sử Lý-Trần)	131 trang PDF scan khắc gỗ, nhiều vết ố, chữ cổ	Cao
HVB_003	Công Dư Tiệp Ký (公餘捷記)	Vũ Phương Đề (Tập truyện truyền kỳ)	60 trang PDF scan khắc gỗ, nhiều dị bản, mờ góc	Cao
HVB_004	Đại Nam Quốc Sử Diễn Ca	Lê Ngô Cát, Phạm Đình Toái (Thơ lục bát)	71 trang chữ Nôm viết tay, chữ tự tạo, dạng thơ	Rất cao
HVB_005	Đ.Việt Lịch Triều Đăng Khoa Lục	Nhiều tác giả (Ghi chép thi cử)	386 trang kết hợp scan/text, nhiều thuật ngữ sử học	Trung bình

Nguồn thu thập dữ liệu: Dữ liệu được thu thập từ các kho lưu trữ số hóa uy tín bao gồm: **Thư viện Quốc gia Việt Nam** (nlv.gov.vn – HVB_002, 003, 005), **Nom Foundation** (nomfoundation.org – HVB_004), **CText.org** (HVB_001) và thông tin đối chiếu từ **Viện Nghiên cứu Hán Nôm** (hannom.org.vn).


2.1 Mô hình và Công cụ thực thi

Pipeline xây dựng dựa trên việc kết hợp các công cụ xử lý ảnh và mô hình học sâu tiên tiến:

- **Vision-Language Model (Qwen3-VL-4B-Instruct):** Mô hình thị giác-ngôn ngữ chính đảm nhận trích xuất ký tự (OCR) cho cả tiếng Việt và các cột chữ Hán cổ.
- **Text Detection (PaddleOCR PP-OCRv5):** Mô hình chuyên biệt dùng để phát hiện vị trí các ô chữ (bounding boxes) và hỗ trợ phân nhóm bố cục cột dọc.
- **Sentence Embeddings (LaBSE & mBERT):** Sử dụng LaBSE (Google) cho biểu diễn ngữ nghĩa đa ngôn ngữ Hán-Việt và bert-base-multilingual-cased để bổ sung tín hiệu ngữ cảnh.
- **Thư viện xử lý & Render (PyMuPDF):** Render các trang PDF Scan thành ảnh PNG chất lượng cao (300 DPI) và hỗ trợ trích xuất text layer trực tiếp.

3 Quy trình thực hiện

Quy trình xử lý được chia thành 3 module chính trong repository `nlp-k35-midterm`:



Hình 1: Sơ đồ luồng xử lý tổng thể 3 module trong pipeline.

```

nlp-k35-midterm/
|-- data/
|   |-- config.json
|   |-- raw/
|       |-- sino/
|       |-- vie/
|       `-- ...
|   |-- ocr_output/
|       |-- HVB_001_sino_raw.txt
|       |-- HVB_001_vie_raw.txt
|       |-- HVB_002_sino_raw.txt
|       |-- HVB_002_vie_raw.txt
|       `-- ...
|   `-- corpus/
|       |-- HVB_001_parallel.tsv
|       |-- HVB_002_parallel.tsv
|       |-- HVB_003_parallel.tsv
|       |-- HVB_004_parallel.tsv
|       `-- HVB_005_parallel.tsv
|
|-- src/
|   |-- ocr/
|       |-- sino_ocr.ipynb
|       |-- vie_ocr.ipynb
|   |-- sentence_alignment/
|       |-- run.py

```

THƯ MỤC CHỨA DỮ LIỆU INPUT & OUTPUT
Cấu hình 5 tác phẩm
Dữ liệu đầu vào thô
File gốc Hán/Nôm (không sửa)
File gốc chữ Việt (không sửa)

Text thô sau OCR
899 dòng
6,479 dòng
1,271 dòng
15,689 dòng

Corpus song ngữ Hán--Việt (TSV)
2,654 cặp
1,712 cặp
756 cặp
1,098 cặp
5,234 cặp

MÃ NGUỒN THỰC THI CHÍNH


[1] OCR Hán/Nôm
[2] OCR Quốc ngữ

[3] Đóng hàng câu

Hình 2: Cấu trúc thư mục chi tiết và các script thực thi chính trong dự án

Bước 1: Tiền xử lý ảnh & OCR (Optical Character Recognition)

Đối với tài liệu Quốc ngữ, từng trang PDF/ảnh được đưa trực tiếp vào mô hình **Qwen3-VL-4B-Instruct** (Hình 3). Nhờ đặc thù trình bày ngang với font hiện đại, mô hình tự động nhận diện bố cục và trích xuất toàn bộ văn bản mà không cần bước phát hiện vùng chữ (text detection) hay sắp xếp thứ tự đọc.



Hình 3: Pipeline OCR tiếng Việt (src/ocr/vie_ocr.ipynb)

Đối với tài liệu Hán/Nôm (Hình 4), pipeline gồm 2 giai đoạn: (1) sử dụng **PaddleOCR** phát hiện các vùng chữ và sắp xếp thành các cột dọc từ phải sang trái; (2) cắt từng dải ảnh cột đưa vào **Qwen3-VL-4B-Instruct** để nhận diện chuỗi ký tự.



Hình 4: Pipeline OCR tác phẩm tiếng Hán/Nôm (src/ocr/sino_ocr.ipynb)

Thách thức: Chữ Hán cổ viết dọc (từ phải sang trái, trên xuống dưới), bố cục cột dạng sách cổ làm các mô hình OCR thông thường dễ nhận diện sai thứ tự đọc.

Giải pháp: Sử dụng **PaddleOCR** phát hiện các vùng ký tự, áp dụng thuật toán `group_boxes_into_columns` gom nhóm bounding boxes để cắt thành các dải cột dọc (từ phải sang trái). Sau đó, đưa từng dải cột vào VLM **Qwen3-VL-4B-Instruct** để nhận diện ký tự từ trên xuống dưới.

Bước 2: Phân khối văn bản (Chunking) và Khởi tạo ngữ cảnh Văn bản cổ thường không có dấu chấm câu (。) hoặc ngắt dòng tùy tiện, đồng thời thường trộn lẫn giữa thơ và văn xuôi. Pipeline tiến hành chia hai bản Hán - Việt thành các khối (chunk) nối tiếp nhau, đính kèm thêm phần ngữ cảnh lân cận (overlap context) để chuẩn bị đầu vào trọn vẹn nhất cho bước phân tích tự động.

Bước 3: Dóng hàng câu (Sentence Alignment)

Module: src/sentence_alignment/run.py

Phương thức:

1. **Khởi tạo LLM Structured Output:** Gửi toàn bộ văn bản Hán và Việt thô (theo từng lô) cho nền tảng Google AI Studio. Bằng cách thiết lập cấu trúc JSON nghiêm ngặt (Structured Output), mô hình bị ràng buộc phải trả về chính xác mảng các cặp câu Hán - Việt tương ứng.
2. **Nhận diện cấu trúc (Fine-grained Segmentation):** LLM tự động phân tích và nhận diện đoạn văn bản là thơ (tách theo dòng) hay văn xuôi (tách theo vế/mệnh đề ngắn) để ngắt câu hợp logic, luôn lấy bản Hán làm tham chiếu gốc (Ground Truth).
3. **Đóng hàng & Khử nhiễu tự động:** Mô hình dò tìm chính xác câu Việt tương ứng để khớp với câu Hán. Cùng lúc đó, LLM tự động đối chiếu chéo để sửa rác OCR, chuẩn hóa dấu câu và loại bỏ (drop) các câu bị khuyết thiếu một chiều mà tuyệt đối không làm sai lệch ý nghĩa lịch sử.

4 Kết quả đạt được

4.1 Khối lượng dữ liệu xử lý

Bảng 3 tổng hợp số trang và thời gian OCR đã xác nhận. Các số liệu về số câu Hán, số câu Việt và số cặp aligned cần được điền từ terminal output sau khi chạy pipeline Ensemble + Greedy Best-Match trên toàn bộ dữ liệu.

Tác phẩm	Thời gian OCR	Số cặp aligned
HVB_001	khoảng 10 tiếng	1638
HVB_002	khoảng 20 tiếng	3180
HVB_003	khoảng 20 tiếng	473
HVB_004	khoảng 10 tiếng	1734
HVB_005	khoảng 10 tiếng	2829
Tổng	60 tiếng	9854

Bảng 3: Khối lượng dữ liệu và các trường số liệu cần cập nhật từ log của pipeline mới.

4.2 Định dạng kết quả đầu ra

Các sản phẩm đầu ra được tổ chức thống nhất theo cấu trúc thư mục như trình bày ở Hình 2.

Mỗi file `_parallel.tsv` chứa mã cặp (`pair_id`), câu Hán (`han_sentence`) và câu Việt (`viet_sentence`) tương ứng (xem mẫu chi tiết ở Bảng 4).

4.3 Ví dụ kết quả trực quan

Trường hợp thành công: HVB_001 (An Nam Chí Lược)

Input (PDF Text): Văn bản có sẵn text layer, có thể trích xuất trực tiếp từ PDF/HTML.

Output sau Alignment:

pair_id	han_sentence	viet_sentence
HVB_001_0000	安南志略	An Nam chí lược
HVB_001_0001	黎崱撰	Lê Tắc soạn
HVB_001_0002	卷之一	Quyển chi nhất
HVB_001_0003	春正月帝幸布海口	Mùa xuân tháng giêng vua ngự ra cửa biển Bồ Hải

Bảng 4: Trích đoạn mẫu kết quả dóng hàng song ngữ Hán-Việt

Nhận xét: Alignment chính xác 100%, giữ được cấu trúc câu.

Trường hợp thành công: HVB_004 (Đại Nam Quốc Sử Diễn Ca)

Input (PDF Text - Chữ Nôm viết tay): Bản viết tay có xen chữ Nôm, chữ Hán và bản phiên âm/dịch nghĩa.

Output sau OCR + Alignment:

pair_id	han_sentence	viet_sentence
HVB_004_0123	百 [chữ Nôm: năm] bờ cõi đất Việt	Trăm năm bờ cõi đất Việt
HVB_004_0124	[chữ Nôm: một] nhà họ Nguyễn dựng nền thái bình	Một nhà họ Nguyễn dựng nền thái bình

Bảng 5: Trích đoạn mẫu kết quả OCR và dóng hàng câu chữ Nôm

Nhận xét: OCR nhận diện được chữ Nôm ([chữ Nôm: năm] = năm, [chữ Nôm: một] = một), alignment giữ được thể thơ lục bát.

Trường hợp khó: HVB_002 (An Nam Chí Nguyên)

Input (PDF Scan - Chữ khắc gỗ, nhiều vết ố): Ảnh scan có nhiều nền và chữ khắc gỗ không đều nét.

OCR Output (có lỗi):

安南志原
高熊微撰
卷之一

Sau LLM Correction:

安南志原
高熊微撰
卷之一

Nhận xét: LLM sửa được lỗi OCR dựa trên ngữ cảnh, đặc biệt ở phần tên tác giả và phần mở đầu sách.

Trường hợp thất bại: HVB_003 (Công Dư Tiệp Ký)

Input (PDF Scan chất lượng kém): Một số trang bị mờ, rách góc hoặc mất nét chữ ở vùng biên.

OCR Output:

公□□記
□□□不可辨
多處墨跡與破損

Nhận xét: OCR thất bại ở nhiều chữ do chất lượng scan kém; LLM cũng không sửa được do thiếu context và ký tự bị mất hoàn toàn.

5 Đánh giá và thảo luận

5.1 Cách đánh giá

Do thiếu tập Ground-truth (nhãn chuẩn) cho văn bản cổ, nhóm sử dụng phương pháp đánh giá thủ công (Manual Sampling) trên 100 mẫu ngẫu nhiên mỗi tác phẩm, kết hợp với việc đối chiếu trực tiếp với file PDF gốc.

5.2 Kết quả đánh giá chi tiết

OCR Tiếng Việt (Quốc ngữ)

Pipeline `vie_ocr.ipynb` đạt độ chính xác cao (~99%). Mô hình Vision-Language **Qwen3-VL-4B-Instruct** thể hiện năng lực nhận diện vượt trội trên dữ liệu chữ Quốc ngữ đầu thế kỷ 20, bảo toàn chính xác các ký tự

đặc biệt, dấu câu và cấu trúc đoạn văn. Văn bản thu được đạt độ sạch cao, tạo tiền đề thuận lợi cho bước dóng hàng.

OCR Tiếng Hán / Chữ Nôm

Pipeline `sino_ocr.ipynb` đạt độ chính xác ở mức khả dụng (~75%). Một số hạn chế chính bao gồm:

1. **Ký tự Nôm đặc thù:** Một số chữ Nôm tự tạo của người Việt chưa có trong tập huấn luyện của PaddleOCR, dẫn đến việc nhận diện nhầm thành các chữ Hán có nét hoặc bộ thủ tương tự.
2. **Vết ố & mực loang:** Hiện tượng mực thấm qua chất liệu giấy dó khiến mô hình đôi khi nhầm lẫn vết loang với dấu chấm hoặc nét chữ rác.
3. **Phân đoạn bố cục:** Bounding box từ PaddleOCR đôi khi gộp hai cột dọc làm một, ảnh hưởng đến thứ tự trích xuất dòng.

Hiệu quả Dóng hàng (Sentence Alignment)

Pipeline tự động hóa hoàn toàn bằng LLM Structured Output mang lại những cải tiến vượt trội:

- Triệt tiêu hoàn toàn hiện tượng lệch pha và bỏ sót câu hàng loạt so với phương pháp tính toán khoảng cách Vector truyền thống, nhờ khả năng nắm bắt ngữ cảnh toàn cục (Global Context) của mô hình ngôn ngữ lớn.
- Khắc phục triệt để thách thức bất đồng bộ phân đoạn (Segmentation Imbalance) giữa Hán và Việt. Bằng năng lực suy luận ngữ nghĩa đa ngôn ngữ (Cross-lingual Reasoning), LLM tự động ngắt vế hoặc gộp ý linh hoạt để tạo ra các cặp dóng hàng chuẩn xác bất chấp sự chênh lệch độ dài.

Hạn chế còn tồn tại:

1. **Nút thắt về Giới hạn Ngữ cảnh (Context Window & Output Limits):** Quá trình xử lý khối văn bản lớn đòi hỏi chiến lược chia lô (batching) chặt chẽ. Nếu lô dữ liệu quá lớn, hệ thống đối mặt với rủi ro vượt ngưỡng độ dài đầu ra cho phép (Max Output Tokens) của API, dẫn đến việc văn bản bị cắt xén (truncation).
2. **Phụ thuộc tài nguyên đám mây (API Dependency):** Hiệu năng và tốc độ dóng hàng phụ thuộc trực tiếp vào băng thông, thời gian phản hồi (Latency) và giới hạn truy vấn (Rate Limits) của nền tảng Google AI Studio, làm giảm tính chủ động so với các mô hình triển khai cục bộ (Local Deployments).

6 Kết luận và hướng phát triển

6.1 Các kết quả đã đạt được

- Xây dựng hoàn chỉnh pipeline tự động hóa end-to-end từ dữ liệu PDF → OCR → Tách câu → Dóng hàng song ngữ.
- Đạt độ chính xác OCR chữ Quốc ngữ vượt trội (~99%), tạo tiền đề dữ liệu chất lượng cho quá trình dóng hàng.
- Triển khai thành công thuật toán xử lý bố cục chữ Hán cổ, trích xuất chính xác thứ tự dòng/cột theo văn bản gốc.

6.2 Hướng phát triển trong tương lai

1. **Cải thiện OCR Hán/Nôm:** Thu thập dữ liệu chữ Nôm chuyên biệt (Nom Foundation) để fine-tune PaddleOCR hoặc thử nghiệm các mô hình nhận diện tiên tiến như Surya OCR hay GOT-OCR2.0.
2. **Nâng cấp thuật toán Alignment:**
 - Fine-tune các mô hình embedding (mBERT/LaBSE) trên song ngữ Hán-Việt cổ nhằm nâng cao độ chính xác biểu diễn ngữ nghĩa.
 - Áp dụng Thuật toán Hungarian (Hungarian Algorithm) để tìm phương án ghép cặp 1-1 tối ưu toàn cục thay cho Greedy Best-Match.
 - Thử nghiệm Few-shot Prompting với LLM ngữ cảnh lớn (Gemini 1.5 Pro, DeepSeek) để dóng hàng cấp chương/toàn văn.
3. **Hoàn thiện bộ dữ liệu HVB:** Đa dạng hóa định dạng xuất dữ liệu (.tsv, .xlsx) kết hợp rà soát thủ công nhằm tạo bộ song ngữ Hán-Việt chuẩn hóa cho cộng đồng nghiên cứu.

Tài liệu tham khảo & Mã nguồn

- **Mã nguồn GitHub:** <https://github.com/james2072/nlp-k35-midterm>
- **Mô hình & Thư viện:** Qwen3-VL-4B, PaddleOCR, LaBSE, mBERT, PyMuPDF, pydantic, OpenCV, google-genai.
- **Nguồn dữ liệu:** Thư viện Quốc gia Việt Nam, Nom Foundation, CText.org, Viện Nghiên cứu Hán Nôm.